

PROJECT SUMMARY

Global E-Commerce Sales & Customer Data

Análise Temporal · Produto · Regional · Clientes · Decomposição

Ferramenta → SQL + Power BI

Dataset → Global E-Commerce (Kaggle)

Dimensão → 2.000 registos · 15 variáveis (colunas)

Repositório → github.com/Etelvino24/global-e-commerce-analytics.git



Etelvino Ngola Joaquim

Analista de Dados

✉ etelvino.joaquim@outlook.com

in [LinkedIn](#)

🔗 [GitHub](#)

INTRODUÇÃO

Este documento tem como objetivo contextualizar o projeto, apresentando as decisões analíticas, o tratamento dos dados e a metodologia adotada para construção do modelo analítico. Os resultados, insights e recomendações de negócio são apresentados separadamente na apresentação executiva (relatório de rentabilidade – power point) e nos dashboards interativos do Power BI.

Mais do que construir dashboards, este projeto procura responder às principais questões estratégicas de um negócio de e-commerce: o negócio está realmente a crescer? Esse crescimento é sustentável? Quais fatores explicam as maiores quedas e picos de lucro? Quais regiões e categorias geram valor e quais comprometem a rentabilidade?

OBJETIVO DO PROJETO

- Identificar se o negócio está a crescer, e se esse crescimento é estável ou volátil (YoY trimestral e coeficiente de variação)
- Diagnosticar, através de decomposição, os factores (categoria, país, segmento, driver) por trás das maiores variações de lucro
- Avaliar a rentabilidade por categoria de produto e identificar o que mais consome a margem (custo, desconto ou envio)
- Analisar a eficiência regional/continental e a dependência de desconto por mercado
- Entender o perfil de rentabilidade de cada segmento de cliente (margem % vs. ticket médio)
- Transformar dados em informação útil para apoiar decisões claras sobre o negócio

Todas as análises foram estruturadas para responder perguntas de negócio específicas e produzir diagnósticos acionáveis.

S O B R E O S D A D O S

Fonte Kaggle → Global E-Commerce Sales & Customer Data

Volume → 2.000 Transações · 15 variáveis

Formato CSV → Tabular

Ferramentas SQL + Power BI

No cenário moderno do comércio eletrônico, a tomada de decisões orientada por dados é fundamental para o crescimento dos negócios. Este conjunto de dados simula 3 anos de transações globais de e-commerce (janeiro de 2023 – dezembro de 2025) para um varejista online fictício de múltiplas categorias que opera em 20 países e 5 regiões geográficas. Ele foi desenvolvido especificamente para a criação de dashboards interativos no Microsoft Power BI e no Tableau, além de servir para a prática de análise de dados, visualização de dados e habilidades de business intelligence.

V A R I Á V E I S U T I L I Z A D A S N A A N Á L I S E

Campo	Representa
order_id	Identificador único do pedido (ORD-10001 a ORD-12000)
order_date	Data da transação (2023-01-01 a 2025-12-31)
customer_name	Nome do cliente
customer_segment	Segmento do cliente (Consumer / Corporate / Home Office)
country	País do cliente (20 países)
region	Região geográfica (5 regiões)
product_category	Categoria do produto (Technology / Furniture / Office Supplies / Clothing & Accessories)
product_name	Nome do produto (40 produtos únicos)
quantity	Quantidade de itens vendidos (1–15)
unit_price	Preço unitário do produto (USD)
discount_percent	Desconto aplicado (0%–30%)
total_sales	Receita do pedido (usada diretamente, sem recalcular)
shipping_cost	Custo de envio do pedido
profit	Lucro líquido após custo do produto e envio
payment_method	Método de pagamento

Nota: o campo **product_cost** (custo do produto) não existe na tabela original de 15 colunas — foi isolado através da fórmula inversa do profit ($total_sales - shipping_cost - profit$) e adicionado como coluna calculada na tabela orders.


MODELAÇÃO DE DADOS

Da tabela flat original (15 colunas) a um modelo relacional em SQL/PostgreSQL.

Os dados chegaram como um único ficheiro CSV, com 15 colunas misturando atributos de entidades distintas — clientes, produtos, localização e pedidos — numa só tabela. Essa estrutura gera redundância e dificulta análises segmentadas por entidade. O ficheiro foi importado para o PostgreSQL através do DBeaver e, a partir daí, normalizado em 4 tabelas relacionais.

Processo de modelação

- **1. Importação** — o ficheiro CSV foi carregado para o PostgreSQL via DBeaver como tabela de staging (global_central).
- **2. Identificação de entidades** — separação entre tabelas entidade — "quem" ou "o quê" (location, products, customers) — e tabela evento — "o que aconteceu" (orders).
- **3. Criação do esquema** — definição de 4 tabelas normalizadas com chaves primárias e estrangeiras, eliminando a redundância da tabela original (ver diagrama).
- **4. População via SQL** — INSERT ... SELECT DISTINCT para as tabelas entidade; DENSE_RANK() sobre customer_name + country + customer_segment para gerar um customer_id artificial e consistente, já que o dataset original não possuía identificador único de cliente.
- **5. Isolamento do product_cost** — a documentação do dataset revelou que profit = total_sales - product_cost - shipping_cost. Como o product_cost não estava exposto, foi isolado pela fórmula inversa e adicionado como coluna calculada na tabela orders.



Modelo relacional final — diagrama gerado no DBeaver (PostgreSQL). As linhas ligam as chaves estrangeiras às respetivas chaves primárias.

Tabela	Tipo	PK	FK
location	Entidade	country	—
products	Entidade	product_id	—
customers	Entidade	customer_id	location
orders	Evento	order_id	customers, products

ESTRATÉGIA ANALÍTICA

Cada análise foi construída em torno de uma pergunta de negócio central, com métricas escolhidas especificamente para a responder.

Análise	Pergunta central	Métricas-chave	O que se pretende descobrir
Temporal	O negócio está a crescer — e esse crescimento é estável ou volátil?	Lucro mensal · Média móvel 3M · YoY trimestral · Coeficiente de Variação	Identificar tendência, consistência e padrões sazonais recorrentes por trimestre.
Produto	O que mais pressiona a margem em cada categoria — e quantos produtos concentram o lucro?	Peso do custo de produto/desconto/envio por categoria / Pareto 80% · Contribuição individual %	Separar categorias saudáveis das que corroem margem, e identificar os produtos-chave do lucro.
Regional	Onde o negócio é eficiente — e onde depende mais de desconto para vender?	Pareto de país · Lucro por continente · Peso do desconto vs. média global	Identificar regiões estratégicas e a dependência de desconto por continente.
Clientes	Qual segmento gera mais valor — e como evolui ao longo do tempo?	Lucro por segmento · Margem % vs. Ticket médio (scatter) · YoY trimestral por segmento	Perfil de rentabilidade por segmento e a sua trajetória trimestral.
Decomposição	O que explica as maiores quedas e picos de lucro (ex: -33% no Q1 2024)?	Self-join YoY · Contribuição % por categoria/país/segmento · Decomposição Volume × Preço × Desconto	Isolar os factores (categoria, geografia, segmento, driver) por trás de quedas e picos específicos.

LIMITAÇÕES

1. **Não foi possível identificar a causa da perda de clientes:** foi possível identificar que a perda de clientes provocou a redução do volume vendido, mas não determinar a causa dessa perda.
2. **Não foi possível explicar as diferenças de desempenho entre países:** foi possível identificar onde ocorreram os maiores impactos, mas não explicar por que determinados países apresentaram desempenhos superiores ou inferiores aos restantes.
3. **A análise identifica relações, mas não comprova causalidade:** os resultados devem ser interpretados como evidências analíticas que apoiam a tomada de decisão, e não como provas definitivas de causalidade.

CONCLUSÃO

Este projeto demonstra a capacidade de construir uma análise de ponta a ponta — desde a normalização de uma tabela flat num modelo relacional em SQL/PostgreSQL até à visualização estratégica e à investigação causal em Power BI.

Através de métodos analíticos como análise temporal, decomposição de indicadores e avaliação da rentabilidade, foi possível identificar padrões de crescimento, diagnosticar os principais fatores responsáveis pelas variações do lucro e transformar dados em informações relevantes para apoiar a tomada de decisão.

Mais do que apresentar métricas, o projeto evidencia a capacidade de estruturar análises orientadas ao negócio, investigar problemas de forma sistemática e comunicar resultados de forma clara, produzindo diagnósticos baseados em evidências e recomendações acionáveis.

COMPETÊNCIAS DEMONSTRADAS

- **Engenharia e Preparação de Dados:** normalização de dados, modelação relacional, criação de chaves artificiais, tratamento de inconsistências e preparação de dados para análise.
- **SQL para Análise de Dados:** utilização de CTEs, Window Functions, Self-Joins e funções analíticas para construção de consultas complexas e decomposição de indicadores de negócio.
- **Business Intelligence:** modelação de dados, desenvolvimento de dashboards e definição de KPIs orientados às necessidades do negócio no Power BI.
- **Métodos Analíticos:** análise temporal, Princípio de Pareto (80/20), decomposição Year-over-Year (YoY), decomposição multiplicativa (Volume × Preço × Desconto) e análise de rentabilidade.
- **Pensamento Analítico:** formulação de perguntas de negócio, investigação das causas das variações de desempenho e transformação de dados em diagnósticos acionáveis.
- **Data Storytelling:** comunicação de resultados através de dashboards e relatórios executivos, convertendo análises técnicas em recomendações para apoio à tomada de decisão.